

Optimización De Datos

 Metodologia Asum-DM

Santiago Rincon
Daniel Cubides
Yahaira Tellez



Date: Diciembre 2025 

Introducción




En este proyecto se realizó un análisis de datos sobre prestadores de servicios públicos, con el fin de comprender la información, mejorar su calidad y aplicar técnicas de analítica de datos para obtener resultados útiles. El trabajo se desarrolló siguiendo la metodología ASUM-DM



Contexto del problema



La información de prestadores de servicios presenta problemas de calidad, como datos incompletos y desorganizados, lo que dificulta su análisis y uso para la toma de decisiones.




Objetivo general

- **Analizar un conjunto de datos de prestadores de servicios mediante la metodología ASUM-DM, realizando un análisis exploratorio, la limpieza de la información y el entrenamiento de un modelo de clasificación, con el fin de identificar patrones y dejar una base de datos preparada para la toma de decisiones.**

Hallazgos del análisis

Contenido

- ¿Qué variables influyen más en la clasificación y el tipo de prestador de servicios de salud?
- ¿Existen patrones significativos en la distribución de los prestadores de servicios de salud según su ubicación geográfica y tipo de servicio?



Descripción del dataset

Contenido

- 13.110 registros
- 14 variables
- Datos administrativos, geográficos y de clasificación
- Información sobre servicios, tipo de prestador y ubicación

Metodología utilizada (ASUM-DM)


Contenido

- Comprensión del problema
- Exploración de los datos (EDA)
- Preparación y limpieza de datos
- Modelado
- Evaluación de resultados



Análisis exploratorio de datos


- Revisión de la estructura del dataset
- Identificación de valores nulos
- Detección de registros duplicados
- Análisis de frecuencias y distribuciones



Principales hallazgos del EDA

Contenido

- Alta presencia de valores nulos en variables clave
- Predominio de variables categóricas
- Inconsistencias en algunos tipos de datos
- Relación entre servicios y clasificación



Limpieza y preparación de datos

Contenido

- Eliminación de registros duplicados
- Corrección de tipos de datos
- Tratamiento de valores nulos
- Preparación del dataset para el modelado

```
data = pd.read_csv('Dataset.csv')

data.info()
```

```
... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 13110 entries, 0 to 13109
Data columns (total 14 columns):
 #   Column                                Non-Null Count  Dtype  
---  -
 0   DEPARTAMENTO_PRESTACION               9286 non-null   object  
 1   MUNICIPIO_PRESTACION                 9286 non-null   object  
 2   SERVICIO                             13110 non-null  object  
 3   ESTADO                              9906 non-null   object  
 4   NOMBRE                               13110 non-null  object  
 5   DEPARTAMENTO_DOMICILIO                13007 non-null  object  
 6   MUNICIPIO_DOMICILIO                  13007 non-null  object  
 7   DIRECCION                            12981 non-null  object  
 8   TELEFONO                             9813 non-null   float64  
 9   EMAIL                                9813 non-null   object  
10   TIPO_INSCRIPCION                     13110 non-null  object  
11   REPRESENTANTE_LEGAL                  12098 non-null  object  
12   TIPO_PRESTADOR                       9365 non-null   object  
13   CLASIFICACION                        9359 non-null   object  
dtypes: float64(1), object(13)
memory usage: 1.4+ MB
```

Modelado de datos

Se importó y utilizó el algoritmo Random Forest para entrenar un modelo de clasificación basado en variables relacionadas con el servicio, el tipo de prestador y la ubicación.

```
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report

target = 'CLASIFICACION'

df_modelo = df_limpio.dropna(subset=[target])

features = [
    'SERVICIO',
    'TIPO_PRESTADOR',
    'DEPARTAMENTO_PRESTACION'
]

X = df_modelo[features]
y = df_modelo[target]

X = pd.get_dummies(X, drop_first=True)

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

modelo = RandomForestClassifier(
    n_estimators=100,
    random_state=42
)

modelo.fit(X_train, y_train)
```

Evaluación y optimización

El modelo fue evaluado mediante métricas de clasificación y posteriormente se realizaron ajustes básicos de hiperparámetros, observando una mejora en su desempeño.

		precision	recall	f1-score	support
**	DESDE 2501 HASTA 5000 USUARIOS	0.40	0.05	0.09	167
	HASTA 2500 SUSCRIPTORES	0.50	0.22	0.31	268
	MAS DE 2500 SUSCRIPTORES	0.25	0.09	0.13	11
	MAYOR O IGUAL A 5001 USUARIOS	0.64	0.86	0.73	595
	MENOR O IGUAL A 2500 USUARIOS	0.64	0.72	0.68	720
accuracy				0.62	1761
macro avg		0.49	0.39	0.39	1761
weighted avg		0.59	0.62	0.58	1761

Organización del proyecto

- Repositorio del proyecto en GitHub
 - Notebook con el análisis y modelado
 - Bitácora de trabajo documentada
 - Roles definidos para cada integrante

Conclusiones

El proyecto permitió comprender, limpiar y analizar un dataset real de prestadores de servicios. A través del análisis exploratorio, la preparación de los datos y el entrenamiento de un modelo de clasificación, se logró una base sólida para futuros análisis y la toma de decisiones.